

移远通信 AI 实战应用大赛 · 复审材料

复审补充：评委问题答复

项目名称：FAE 知识智能治理平台（AI DocClassifier）

赛道：运营提效与职能创新 团队：分类小能手 部门：技术支持部

申报日期：2026 年 09 月 17 日

飞书 Wiki 是企业指定的存储与协作层；分类、抽取、标题、编排、质量治理是我们自研的 Agent 流水线。当前已落地的不是聊天式 RAG，而是让 2 万篇「按人堆放、附件沉睡」的 Sharing 变成可检索、可运营的知识资产——这是后续 RAG / FAE Support Agent 能做准的前提。

一、对初审评语的回答

（一）不是「飞书自带知识库能力」

飞书知识库提供的是：页面编辑、目录、基础全文检索、权限。它不提供、本项目必须自研的能力包括：（1）把 PDF/Word/PPT 附件解析成可检索正文与可显示图片；（2）按 QT-SOP-PM-048E 模组规范约束 LLM，输出 Product Line × Technical Category 叶子路径；（3）把日期/流水号标题改写成「主题-型号-作者」；（4）多 Worker 增量扫描、共享去重、飞书/LLM 限流、操作账本；（5）复制后 enrichment（元数据表、图片重绑）。若只靠飞书自带能力，FAE 仍要在人名文件夹里翻 PDF，标题仍是日期，检索仍找不到附件里的根因。

（二）原生 Agent 是什么、模型是什么、工具是什么

这里的 Agent 不是对话机器人，而是「感知文档 → 调用工具 → 受约束决策 → 写回知识枢纽」的批处理智能体。运行时：OpenAI 兼容网关（LLM_BASE_URL，内部 qlitellm）+ 模型 deepseek-v4-flash（可配置 LLM_MODEL）。每个 Agent 有明确工具集，禁止让模型自由编造分类路径或技术参数。

Agent	职责	模型	工具（自研/接入）
抽取 Agent	PDF/Word/PPT → 正文+表+图写入 Wiki 块	规则为主；图需转码不走视觉大模型	PyMuPDF、python-docx、python-pptx；飞书 medias 上传/下载、docx blocks
分类 Agent	排除过程稿后，输出标签树叶子路径	deepseek-v4-flash	Feishu 扫描/读 raw_content/复制；QT-SOP 正则；LABEL_TREE 约束解码；分类缓存
标题与元数据 Agent	主题-型号-作者；文内元数据表	deepseek-v4-flash	通讯录/源路径作者回退；Wiki 改标题；docx 表格块
编排 Agent	增量、去重、限流、账本、控制台派发	不调用 LLM	scan_snapshot、shared_copy_state、tool_ops、Feishu 限速重试
图片修复 Agent	裂图重绑 / 空图块重提	不调用 LLM	wiki node extra、格式转码、嵌套图块遍历

表 1 已落地的原生 Agent、模型与工具（飞书只提供存储/API，不提供上述决策逻辑）

二、问题 1：PDF / Word 如何抽取正文、表格、图片

目标不是做通用文档解析 SaaS，而是让附件进入与飞书正文同一条分类和检索链路。抽取写回源文档「附件：」分区，复制到 TARGET 后再按 wiki 鉴权重绑图片，避免副本裂图。

（一）PDF（以 PDF 为例的完整路径）

- 打开：PyMuPDF（fitz）按页处理。
- 正文：`page.get_text("blocks")`，取文本块（`type=0`），按块的 `y` 坐标排序，保持近似阅读顺序；每页结束后插入「第 N 页」分隔。
- 表格：当前不单独走 Camelot/版面检测。PDF 表格的单元格会作为空间上相邻的 text block 抽出，写入连续段落。优点是实现稳定、能进全文检索；局限是不保留栅格表结构。Word 表格则按行抽取为「单元格|单元格」文本，结构更好。能检索到表内文字，但 PDF 侧尚未做 HTML/Markdown 表格重建。这是明确的下一阶段优化（见第三节召回）。
- 图片：`page.get_images` 取 XObject；跳过 mask；用页面上的 image rect 决定插入位置（与正文按 `y` 交织）。像素经 pixmap 转 RGB JPEG/PNG：CMYK、JPEG2000、

超大边 (>4096px)、GIF/WEBP/BMP/EMF 一律转码，否则飞书图块会裂图。上传带 extra.drive_route_token（优先 wiki node token），replace_image 写入宽高。

（二）Word / PPT

- Word：段落文本；表格按行拼接；DrawingML blip 与 VML v:imagedata（含表格内图片）；.doc 先转 docx。
- PPT：遍历形状，含 GROUP 递归；文本框与 PICTURE 按坐标排序后写入。

（三）是否多模态 RAG

当前不是 CLIP/视觉向量多模态 RAG。处理策略是「多模态摄入、文本层检索」：图进入 Wiki 图块供人阅读与飞书页面展示；表内文字进入正文供全文检索与 LLM 分类。不做图 embedding、不做页级 OCR 视觉问答。原因：第一瓶颈是 1.7 万篇附件根本进不了索引；先把图和表变成可展示、可检索的资产，再在治理后的 TARGET 上做向量 RAG 才有意义。下一阶段：对关键示意图用视觉模型生成 caption 写入正文，再纳入向量索引。

三、问题 2：抽取之后如何存储、做了哪些优化

存储单元不是向量库，而是「受治理的飞书文档 + 元数据表 + 多维表目录」。这是有意选择：FAE 日常仍在飞书里协作，治理结果必须落在他们已经打开的入口，而不是另建一套只有开发能用的向量库。

- 双空间：SCAN 保留作者原文；TARGET 是分类枢纽副本。整理侧改标题/贴表不回写源，避免污染现场写作。
- 一篇文档的知识包 = 原正文 + 「附件提取」分区（文本/表/图）+ 文首元数据表（原名、源路径、作者、产品线、主题、型号、源创建时间）。
- 对象存储优化：图片绑定 TARGET 的 wiki node，避免 copy 后仍指向 SCAN 媒体 token 导致裂图；存量 17,255 篇已跑修复，重绑约 16.9 万张图，空图块自动从附件重提 698 篇。
- 噪声过滤：周报/日报/会议纪要/客户问题跟踪不入库，缩小检索宇宙。
- 去重与增量：shared_copy_state 按 obj_token 全局去重；scan_snapshot 只处理新增；tool_ops 按操作跳过，避免重复贴表/改名。
- 目录分卷：单层节点过多时按产品线规则 rollover，保证 Wiki 导航可用。

四、问题 3：召回做了哪些优化

当前召回是「结构化过滤 + 全文检索」，不是 embedding Top-K。我们把召回分成已上线和规划中两层，避免把规划说成已上线。

层级	已上线（生产）	作用
L0 语料清洗	排除过程稿；附件正文化；裂图修复	先让该被搜到的字真的在索引里
L1 结构化导航	Product Line × Technical Category 目录树	先缩到产品线/技术域，再搜，降低人名目录噪声
L2 结果可读	标题改为主题-型号-作者；元数据表	搜索命中后 1 秒判断是否值得点开
L3 全文	飞书对 TARGET 正文+抽取区做全文	PDF 里的 AT 命令、报错码可被搜到
L4 目录	多维表导出元数据/展示标题	运营侧按作者、型号、路径筛选

表 2 已上线召回优化（尚未上向量 RAG）

规划中的 L5：在 TARGET + 质量评分达标的语料上建向量索引，做案例问答 / 工单辅助。分类 Agent 已做的「域强制、叶子约束、Others 纠偏」会直接降低 RAG 的脏召回。没有 L0-L3，直接上 RAG，模型会检索到周报、裂图 PDF 和日期标题，这正是我们没有一上来做聊天机器人的原因。

五、除知识库外，还会接入哪些 Agent、用在哪些场景

本项目不是「整个只做一个 RAG 知识库」。它是知识生命周期平台：采集 → 解析 → 分类 → （规划）质量评分 → 人工复核 → 供给下游 Agent。飞书 Wiki 是底座；上面已经有治理 Agent，下一步才是消费侧 Agent。

阶段	Agent / 能力	场景
已上线	抽取 / 分类 / 标题元数据 / 编排 / 图片修复	历史 1.7 万篇治理 + 每日增量归档
试点中（规则已定义）	质量评分 Agent（5 维 25 分，必须给证据）	判断哪些 Sharing 能进对外库或 RAG 白名单
下一阶段	检索问答 Agent（向量 RAG + 目录过滤）	FAE「这个型号以前怎么排过」
下一阶段	工单辅助 Agent	打开客户问题时推荐同型号历史案例与步骤
后续可选	Rewrite Agent（不覆盖原文、人工终审）	B 档文档补步骤/验证，供培训与对外候选

表 3 Agent 路线图：治理必须先于 RAG

可复制性：换标签树和 SCAN/TARGET token，同一套 Agent 可迁到研发/认证/培训知识空间。对外知识库、官网 Qchat、论坛机器人由协作团队建设，本项目输出「已分类、可检索、带质量分」的候选，并非再造一个飞书。

六、本轮新增落地数据（复审可核验）

- 统一枢纽叶子文档：约 17,105 篇分类复制；标题标准化约 17,092 篇（初审口径）。
- 2026-09 附件裂图治理：对 TARGET 17,255 篇跑修复；有图 5,823 篇；重绑 169,010 张；空图块自动重提 698 篇；失败 284 张。
- 提效口径不变：存量约 1 人年已兑现；以后每年约 1.7 FTE，检索复用 1.44 FTE 是大头（公式见计划书）。